



復旦大學

数据、模型与决策

Data, Model and Decisions

第二讲：数据与描述统计

黄达 复旦大学管理学院

统计与数据科学系

dahuang@fudan.edu.cn

- 什么是数据？
- 数据的类型（内涵的信息以及计算）
- 数据中的信息表达：图与表
 - 不同类型数据对应的图表
 - 其他常见的图
 - 图表中的常见误导
 - “奇怪”的图往往含有特殊的信息
- 数据中的信息表达：描述统计
 - 单变量数据中我们一般会关心哪些信息？
 - 集中性的刻画
 - 变异性的刻画
 - 双变量数据中我们一般会关心哪些信息？
 - 协方差
 - 相关系数
 - 相关与因果
- 数据分析实际案例：VIPABC v. s. 看榜科技

- 什么是数据？
- 数据的类型（内涵的信息以及计算）
- 数据中的信息表达：图与表
 - 不同类型数据对应的图表
 - 其他常见的图
 - 图表中的常见误导
 - “奇怪”的图往往含有特殊的信息
- 数据中的信息表达：描述统计
 - 单变量数据中我们一般会关心哪些信息？
 - 集中性的刻画
 - 变异性的刻画
 - 双变量数据中我们一般会关心哪些信息？
 - 协方差
 - 相关系数
 - 相关与因果
- 数据分析实际案例：VIPABC v. s. 看榜科技



復旦大學

数据与其中的信息表达

认识数据

什么是数据



復旦大學

- 数据是信息的载体（内涵）
 - 数据可以被记录
 - 数据可以被分析
- 数据的具体形态多种多样（外延）
 - 数字
 - 文字
 - 图像
 - 声音
 - 视频
 -
- 当一个事物过于复杂时，常用的处理方式：分而治之

- 什么是数据？
- 数据的类型（内涵的信息以及计算）
- 数据中的信息表达：图与表
 - 不同类型数据对应的图表
 - 其他常见的图
 - 图表中的常见误导
 - “奇怪”的图往往含有特殊的信息
- 数据中的信息表达：描述统计
 - 单变量数据中我们一般会关心哪些信息？
 - 集中性的刻画
 - 变异性的刻画
 - 双变量数据中我们一般会关心哪些信息？
 - 协方差
 - 相关系数
 - 相关与因果
- 数据分析实际案例：VIPABC v. s. 看榜科技

数据的类型



復旦大學

- 按总体与部分

- 总体数据（描述统计）
- 样本数据（描述统计 + 推断统计）

- 按来源

- 现有数据（历史数据，如统计年鉴、气象记录等）
- 调查数据（某新型药物是否对人体有害，是否有效？）

- 按变化方式

- 常量：光速、 e 、 π
- 变量：日期、年龄
- 随机变量：
 - 今年患某种疾病的病人人数有多少？
 - 你今晚几点钟到家？

数据的类型



復旦大學

- 按信息含量

- 名义：男女、学号、某种疾病
- 顺序：名次、学位
- 间隔：考试分数
- 比例：年龄、跑步的距离

离散变量

连续变量

- 其他类型的数据：文字、图像，声音，视频都可以用这些变量表示。

	=, ≠	>, <	四则运算	其他运算（如指数、开方等）
名义	Y	N	N	N
次序	Y	Y	N	N
间隔	Y	Y	+、-	N（除非可以确定零点）
比例	Y	Y	Y	Y

- 机器学习中的“嵌入”技术可以将离散变量转为连续变量

- 什么是数据？
- 数据的类型（内涵的信息以及计算）
- 数据中的信息表达：图与表
 - 不同类型数据对应的图表
 - 其他常见的图
 - 图表中的常见误导
 - “奇怪”的图往往含有特殊的信息
- 数据中的信息表达：描述统计
 - 单变量数据中我们一般会关心哪些信息？
 - 集中性的刻画
 - 变异性的刻画
 - 双变量数据中我们一般会关心哪些信息？
 - 协方差
 - 相关系数
 - 相关与因果
- 数据分析实际案例：VIPABC v. s. 看榜科技



数据与其中的信息表达

常见的图与表


数据中的信息（图）



復旦大學



● 离散型数据（定性）

日期	走势
2000-01-05	上涨
2000-01-06	上涨
2000-01-07	上涨
2000-01-10	上涨
2000-01-11	下跌
2000-01-12	下跌
2000-01-13	下跌
2000-01-14	下跌
2000-01-17	上涨
2000-01-18	下跌
2000-01-19	上涨
2000-01-20	上涨
2000-01-21	下跌
2000-01-24	上涨



- 离散型数据（定性）

日期	走势
2000-01-05	上涨
2000-01-06	上涨
2000-01-07	上涨
2000-01-10	上涨
2000-01-11	下跌
2000-01-12	下跌
2000-01-13	下跌
2000-01-14	下跌
2000-01-17	上涨
2000-01-18	下跌
2000-01-19	上涨
2000-01-20	上涨
2000-01-21	下跌
2000-01-24	上涨



变化

- 上涨
- 下降

数据中的信息（图）



復旦大學

- 离散型数据（定性）：

- 股市的涨跌规律？

- 2000年1月4日-2022年8月10日，比较前后两个交易日上证指数的收盘价

	上涨	持平	下跌	合计
交易日数	2899	0	2578	5477
交易日比例	52.93%	0%	47.07%	100%

	后一交易日上涨	后一交易日下跌	合计
前一交易日上涨	1521 (27.78%)	1378 (25.16%)	2899 (52.94%)
前一交易日下跌	1377 (25.15%)	1200 (21.91%)	2577 (47.06%)
合计	2898 (52.93%)	2578 (47.07%)	5476 (100%)

数据中的信息（图）



- 离散型数据（定序）

Rank	University	Articles	Score	Country
1	University of Pennsylvania (The Wharton School)	408	198.59	USA
2	University of Texas at Dallas (Naveen Jindal School of Management)	330	158.60	USA
3	Columbia University (Columbia Business School)	323	148.31	USA
4	Harvard University (Harvard Business School)	296	137.16	USA
5	University of Chicago (Booth School of Business)	290	130.40	USA
6	New York University (NYU) (Leonard N Stern School of Business)	306	125.15	USA
7	University of Southern California (Marshall School of Business (incl. Leventhai))	267	118.09	USA
8	Massachusetts Institute of Technology (MIT) (Sloan School of Management)	291	117.64	USA
9	INSEAD (School of Business)	264	114.79	France
10	Indiana University at Bloomington (Kelley School of Business)	275	110.64	USA
11	Stanford University (Graduate School of Business)	237	108.18	USA
12	University of Texas at Austin (McCombs School of Business)	230	104.40	USA
13	Cornell University (SC Johnson College of Business, Johnson Graduate School of Management (Incl. Dyson and Nolan))	239	100.03	USA
14	University of Toronto (Joseph L. Rotman School of Management)	248	98.51	Canada
15	University of Hong Kong (Faculty of Business and Economics / HKU Business School))	255	94.10	China

<https://isom.utdallas.edu/the-utd-top-100-business-school-research-rankings/worldRankings#20212025>

数据中的信息（图）




復旦大學


- 连续型变量（定比）

- 上证指数收益率（上证综合指数2010.1.4-2022.8.10）

上证指数收益率（收盘价）时间序列图（2010.1.4-2022.8.10）



上证A股收益率（收盘价）分布




数据中的信息（图）



復旦大學

● 连续型数据（定距）

数据来源：上海市教育考试院网站



数据中的信息（图）




復旦大學

- 你应该先抢还是后抢？
 - 先抢比后抢会多抢到钱么？还是后抢比先抢会抢到更多的钱？
 - 不同的人数抢红包，谁更有可能抢到“最佳手气”？

源自《一席》毕啸天演讲《一本正经胡说八道》

数据中的信息（图）


- 5人，50元红包，150次



源自《一席》毕啸天演讲《一本正经胡说八道》

数据中的信息（图）

- 5人，50元红包，5000万次




源自《一席》毕啸天演讲《一本正经胡说八道》

数据中的信息（图）



复旦大学

- N个人抢N个红包，抢到最佳手气的概率



源自《一席》毕啸天演讲《一本正经胡说八道》

数据中的信息（图）




復旦大學

- 这张图里有什么信息？是否蕴涵了某种规律？

《数据分析引论》65名学生出生时间

Three hours moving average 前后3小时的滑动平均

没有征集生产方式






数据与其中的信息表达

其他常见的图

数据中的信息（图）



復旦大學




数据中的信息（图）




復旦大學

● 网络图

三国演义主要人物关系图



● 词频图




数据中的信息（图）



復旦大學

• 热力图



前Boston Red Sox棒球队传奇巨星 Ted Williams一次比赛的照片。




数据中的信息（图）



復旦大學

- 同样重要的，**是知道怎么看！**
- 比如营销中常用的RFM模型
 - R: Recency
 - F: Frequency
 - M: Monetary





数据与其中的信息表达

常见图表忽悠法

(己之不欲，勿施于人)

常见图表忽悠法



復旦大學

图1 国内生产总值增长速度（季度同比）



图2 规模以上工业增加值增速（月度同比）



图3 社会消费品零售总额增速（月度同比）



图4 固定资产投资（不含农户）增速（累计同比）




来源: <https://baijiahao.baidu.com/s?id=1738407581813312262&wfr=spider&for=pc>



常见图表忽悠法



復旦大學





常见图表忽悠法



常见图表忽悠法



復旦大學



常见图表忽悠法



復旦大學




兰小欢

9分钟前 来自 微博 weibo.com

昨天美国的就业数据出来以后，CNBC放了左图，是每月环比就业人数的变化，大呼“V形反弹”。经济学界Wolfers放了右图，是就业人数总量...

收起 | 查看大图 | 向左旋转 | 向右旋转




兰小欢

9分钟前 来自 微博 weibo.com

昨天美国的就业数据出来以后，CNBC放了左图，是每月环比就业人数的变化，大呼“V形反弹”。经济学界Wolfers放了右图，是就业人数总量...

收起 | 查看大图 | 向左旋转 | 向右旋转





小结：拿到数据后先不要急着跑模型，做一些表和图，这样会对数据有第一手的认识。但是光看图是不行的，容易被误导，所以还得看数。

- 什么是数据？
- 数据的类型（内涵的信息以及计算）
- 数据中的信息表达：图与表
 - 不同类型数据对应的图表
 - 其他常见的图
 - 图表中的常见误导
 - “奇怪”的图往往含有特殊的信息
- 数据中的信息表达：描述统计
 - 单变量数据中我们一般会关心哪些信息？
 - 集中性的刻画
 - 变异性的刻画
 - 双变量数据中我们一般会关心哪些信息？
 - 协方差
 - 相关系数
 - 相关与因果
- 数据分析实际案例：VIPABC v. s. 看榜科技



描述统计

- 如果有很多数，比如说10000个数： $x_1, \dots, x_{10000}$
- 显然，我们要是每个数都看的话，是不现实的。
- 所以，我们需要将这些数浓缩成若干个指标（描述统计量），把这堆数中的重要信息提取出来。
- 拿到一个数据集后我们想做什么？
 - 数据内含有信息，我们想获取数据中的信息。
 - 要获取所有的信息，最好的办法是所有的数据都看一遍。数据量很大的时候我们无法做到。
 - 我们希望能够提取出一些少量但是重要的信息出来
- 讨论：
 - 哪些信息重要？（举例说明）
 - 哪些指标对应着这些信息？

预备知识



復旦大學

- 假定有比率数据 $x_1, x_2, \dots, x_n$
- 排序后的数据 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$
- 数据的和: $S_n = \sum_{i=1}^n x_i = x_1 + x_2 + \dots + x_n$
 - 有时候简写成 $\sum x_i$



单变量数据的描述统计 如何刻画“集中位置”

描述统计（众数）



復旦大學

- 平均涉及到四则运算
- 定性数据无法进行四则运算，不存在平均数

- 问：如何解决？

- 答：众数？（出现次数最多的那类）

- 例子：重大事项的投票

- $2/3$ 以上出席，出席者 $1/2$ 以上通过

描述统计（众数）



復旦大學

2026年河南省普通高招分数段统计表(物理类)

(统计表中“考生人数”为加入政策性照顾分后对应总分及以上考生累计人数)

分 数	考生人数	分 数	考生人数	分 数	考生人数
463	269830	436	326066	409	378789
462	271880	435	326227	408	380606
461	274071	434	330296	407	382462
460	276187	433	332338	406	384315
459	278328	432	334329	405	386076
458	280457	431	336309	404	387912
457	282616	430	338299	403	389619
456	284695	429	340374	402	391351
455	286795	428	342348	401	393105
454	288870	427	344306	400	394902
453	290975	426	346277	399	396650
452	293060	425	348208	398	398390
451	295147	424	350200	397	400060
450	297262	423	352205	396	401788
449	299359	422	354177	395	403471
448	301400	421	356186	394	405205
447	303496	420	358110	393	406912
446	305609	419	359972	392	408561
445	307689	418	361927	391	410167
444	309819	417	363819	390	411800
443	311863	416	365821	389	413412
442	313946	415	367557	388	415061
441	316081	414	369414	387	416762
440	318037	413	371295	386	418324
439	320094	412	373155	385	419957
438	321988	411	375059	384	421543
437	324045	410	376933	383	423020

2026年河南省普通高招分数段统计表(物理类)

(统计表中“考生人数”为加入政策性照顾分后对应总分及以上考生累计人数)

分 数	考生人数	分 数	考生人数	分 数	考生人数
544	106845	517	157450	490	212769
543	108630	516	159452	489	214826
542	110323	515	161448	488	216954
541	112055	514	163430	487	219125
540	113849	513	165386	486	221269
539	115590	512	167379	485	223365
538	117402	511	169441	484	225395
537	119176	510	171480	483	227477
536	121040	509	173540	482	229584
535	122901	508	175563	481	231661
534	124764	507	177603	480	233796
533	126552	506	179565	479	235862
532	128394	505	181638	478	237969
531	130228	504	183673	477	240122
530	132163	503	185729	476	242257
529	134138	502	187738	475	244387
528	136057	501	189753	474	246490
527	137897	500	191837	473	248567
526	139845	499	193885	472	250712
525	141785	498	195941	471	252894
524	143717	497	198032	470	255054
523	145684	496	200146	469	257166
522	147674	495	202262	468	259357
521	149577	494	204305	467	261462
520	151455	493	206437	466	263544
519	153396	492	208563	465	265656
518	155452	491	210678	464	267720

描述统计（简单算术平均）



復旦大學

- 假定现在你手里有 k 支股票
- 每只股票你只有1股
- 每只股票1元/股
- 股票收益率依次为： $x_1, x_2, \dots, x_k$
- 问题：你如何衡量你的收益？

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_k}{k} = \frac{1}{k} \sum_{i=1}^k x_i$$

描述统计（加权算术平均）



復旦大學

- 假定现在你手里有 k 支股票
- 第 i 只股票，有 n_i 股
- 每只股票1元/股
- 股票收益率依次为： $x_1, x_2, \dots, x_k$
- 问题：你如何衡量你的收益？

$$\bar{x} = \frac{x_1 n_1 + x_2 n_2 + \dots + x_k n_k}{n_1 + n_2 + \dots + n_k} = \frac{1}{n} \sum_{i=1}^k x_i n_i = \sum_{i=1}^k \frac{n_i}{n} x_i$$

- 注： $n = n_1 + \dots + n_k$
- 令 $w_i = \frac{n_i}{n}$ ，上式可以写成 $\bar{x} = \sum_{i=1}^k w_i x_i$

描述统计（加权算术平均）



復旦大學

- 假定现在你手里有 k 支股票
- 每只股票有1股
- 第 i 只股票价格为 p_i 元/股
- 股票收益率依次为： $x_1, x_2, \dots, x_k$
- 问题：你如何衡量你的收益？

$$\bar{x} = \frac{x_1 p_1 + x_2 p_2 + \dots + x_k p_k}{p_1 + p_2 + \dots + p_k} = \frac{1}{p} \sum_{i=1}^k x_i p_i = \sum_{i=1}^k \frac{p_i}{p} x_i$$

- 注： $p = p_1 + \dots + p_k$
- 令 $w_i = \frac{p_i}{p}$ ，上式可以写成 $\bar{x} = \sum_{i=1}^k w_i x_i$

描述统计（加权算术平均）



復旦大學

- 假定现在你手里有 k 支股票
- 第 i 只股票，有 n_i 股
- 第 i 只股票价格为 p_i 元/股
- 股票收益率依次为： $x_1, x_2, \dots, x_k$
- 问题：你如何衡量你的收益？

$$\bar{x} = \frac{x_1 n_1 p_1 + x_2 n_2 p_2 + \dots + x_k n_k p_k}{n_1 p_1 + n_2 p_2 + \dots + n_k p_k} = \sum_{i=1}^k w_i x_i$$

- 注： $w_i = \frac{n_i p_i}{n_1 p_1 + \dots + n_k p_k} \geq 0$ ，且 $w_1 + \dots + w_k = 1$

描述统计（中位数）



復旦大學

- 平均的缺陷：
 - 被平均了……☹
 - 还没跑赢大盘……☹☹
 - 对不起，又拖了祖国的后腿……☹☹☹
- 为什么会有这种现象？
- 问：平均数的缺陷是什么？
- 答：容易受极值影响。
- 问：如何解决？
- 答：中位数 x_{MED} （大小排在中间的那个数）
 - 即 $x_{((n+1)/2)}$ 或 $(x_{(\frac{n}{2})} + x_{(\frac{n+2}{2})})/2$

补充：几何均值



復旦大學

- 假定你有一只股票，持有了 T 天，第 i 天的收益率为 r_i ，日均收益率怎么算？
- $(1 + r_1)(1 + r_2) \cdots (1 + r_T) = (1 + \bar{r})^T$
- 几何均值 (geometric mean/average)
 - $(x_1 x_2 \cdots x_n)^{1/n}$ (x_i 必须为正数)
 - 适用场合：平均增长率等
 - 金融收益率
 - GDP 增长率
 - 年均增长率




单变量数据的描述统计 如何刻画离散（离心）

数据中的信息（变异性）



復旦大學

● 阅兵中的“变异”性



数据中的信息（变异性）



復旦大學


- 极差

- $x_{(n)} - x_{(1)}$

- 四分位差

- $Q_3 - Q_1$

- 注意与蜡烛图的区别




数据中的信息（变异性）



復旦大學

- 盒子图（箱线图的局限性）



数据中的信息（变异性）



復旦大學

• 方差 (variance)

$$\bullet \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$




• 标准差 (Standard Deviation): σ

• 直观解释

- $\sigma \geq 0$, ($\sigma = 0$ 表示变异程度为0)
- σ 大小与变异程度大小对应

• 备注：样本方差

$$\bullet s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$




数据中的信息（变异性）



復旦大學

- 方差视觉化（上证综合指数2000.1.4-2022.8.10）



数据中的信息（变异性）



復旦大學

• 方差的应用

- 在风险管理中的应用（综合考虑收益与波动）
- 在质量控制中的应用（生产出来的零件直径， 6σ ）
- 在体育训练中的应用
- 在教育考试中的应用（标准化考试，下一页）





Fig. 1 Graphical illustration of bias and variance.



CCTV 1

综合

央视新闻 bilibili

开讲啦
VOICE

开讲啦
VOICE

该课件受版权法保护，不得擅自复制、分发和传播。



多变量数据的简单分析

表与图


变量之间的关系：相关系数



復旦大學

● 备注

- 仅刻画线性相关性，不能刻画非线性相关性
- 例： $x = \cos\theta$, $y = \sin\theta$
- 常见图形与对应的Pearson相关系数：




变量之间的关系



復旦大學

- 上证指数前后连续两个交易日 **涨跌绝对值/相对值** 关系
- 相关系数为0.0238和0.0385


上证综指前后两个连续交易日间的涨跌幅度关系



前一个交易日涨跌幅

涨跌点数（绝对值）

上证综指前后两个连续交易日间的涨跌额度关系



前一个交易日涨跌额


涨跌比例（相对值）

变量之间的关系



復旦大學

- 均值、标准差（方差）、协方差、相关系数等指标的局限性：




X Mean: 54.2659224
Y Mean: 47.8313949
X SD : 16.7649829
Y SD : 26.9342120
Corr. : -0.0642526

变量之间的关系



復旦大學

- 均值、标准差（方差）、协方差、相关系数等指标的局限性：





相关关系与因果关系

相关关系与因果关系



復旦大學

- 注意区分因果关系与相关关系

- 因果 $\Rightarrow$ 相关，反之不然
- 相关分为线性相关和非线性相关（本课程内只讨论线性相关）
- 相关：两件事情经常一起出现，一起不出现，或者一个出现另一个不出现
- 因果：**因为**一件事情，**所以**有另一件事情

- 三种类型的因果关系导致的相关关系

- 因为A，所以B，于是有相关关系
- A和B互为因果，于是有相关关系
- A和B都受到C的影响，于是有相关关系

相关关系与因果关系



復旦大學

- 注意区分因果关系与相关关系



变量之间的关系



復旦大學

- 相关还是因果？哪种因果？（注意区分fact和opinion）



西峯

8分钟前 来自 iPhone 11 Pro 已编辑

社会科学很有意思，主要看话语权在哪里。这个例子也可以解释为：正因为福奇的警告，预防了这样恐怖的结果发生。

@开花富贵老娘发飙

和一个老头聊天，聊到CDC福奇大人说美国人民今年的圣诞节能不能聚会还得走着瞧。

老头说，他年轻那会，艾滋病刚开始传染起来的时候。福奇就警告美国人艾滋病马上就要从在同性恋之间的传播传染到异性恋了，以后就会变成一个人人皆得的病。场面非常恐怖。

当然历史证明和福奇大人的预言是相反的。

当然这不妨碍福奇官运亨通。

Sell fear是市场营销中的制胜法宝之一。 [收起](#)

Unlearned AIDS Lessons for Covid

In the 1980s, Fauci and Redfield sowed about a heterosexual epidemic that ne happened.

By John Tierney
Oct. 3, 2021 5:02 pm ET

SHARE

low the science," we've been told throughout t
id-19 pandemic. But if we had paid attention to
ory, we would have known that once a disease
omes newsworthy, science gets distorted by
archers, journalists, activists and politicians
er for attention and power—and determined to
nce those who challenge their fear-mongering

en AIDS spread among gay men and intraveno
g users four decades ago, it became conventio
dom that the plague would soon devastate the
of the American population...

"I've lost confidence in the CDC and the FDA, and I actually believe a lot of Americans, a significant part of America, now have lost confidence in you, Dr. Fauci," talk show host Hugh Hewitt said.

By Christopher Spencer | Sept. 30, 2021



27分钟前



5



5



26



1




3

相关关系与因果关系



復旦大學

- 具有“延迟满足感”的孩子真的容易成功么？
 - 有两组小孩，面前放一堆糖，告诉他们说，晚点吃会有更多的糖。
 - 有些小孩立刻吃，有些过一会儿再吃。
 - 跟踪研究，那些过一会儿再吃的小孩子，他们今后发展要比那些马上就吃的小孩子要好。
 - 结论：具有“延迟满足感”的小孩更容易成功。



补充：多变量的复杂性



復旦大學

表中是美国职业棒球联盟2002年到2003年两位球员罗尼·贝利亚德（Ronnie Belliard）和凯西·布雷克（Casey Blake）的击打率数据。你觉得谁的表现更好？

年份	运动员	击中数	击打次数	平均击打率
2002	贝利亚德	61	289	0.2111
	布雷克	4	20	0.2000
2003	贝利亚德	124	447	0.2774
	布雷克	143	557	0.2567

- 什么是数据？
- 数据的类型（内涵的信息以及计算）
- 数据中的信息表达：图与表
 - 不同类型数据对应的图表
 - 其他常见的图
 - 图表中的常见误导
 - “奇怪”的图往往含有特殊的信息
- 数据中的信息表达：描述统计
 - 单变量数据中我们一般会关心哪些信息？
 - 集中性的刻画
 - 变异性的刻画
 - 双变量数据中我们一般会关心哪些信息？
 - 协方差
 - 相关系数
 - 相关与因果
- 数据分析实际案例：VIPABC v. s. 看榜科技



復旦大學

描述统计综合案例

VIPABC v. s. 看榜科技



復旦大學

某微信公众号“异常”流量 的 统计分析与司法实践

黄达 复旦大学管理学院

统计与数据科学系

dahuang@fudan.edu.cn

学习要点



復旦大學

- 这是一个关于数据对比的案例，希望同学们在学习中了解并掌握：
- 如何应用基本的描述统计
- 数据的可比性
 - 统计口径的一致性
 - 各种自然属性的一致/相似性
 - 抽样方法
- 数据对比的角度
 - 静态分析与动态分析
 - 流量分析与存量分析
 - 绝对量分析与相对量分析



復旦大學

行业背景与案件背景

行业背景：刷量



復旦大學

➤背景

- 企业投放广告，希望能够对广告效果进行评估
- 传统技术背景下，很难对传播的整个过程进行监测
- 信息技术的进步，使得对广告等传播的实时监测成为可能
- 各方希望对传播的过程与效果有一个量化的评估
- 应运而生的是一个地下产业：刷量



行业背景：刷量



復旦大學



行业背景：刷量



復旦大學

➤刷量的动机

- 提升传播相关的量化指标，完成企业所指定的业绩要求。
- 作为自己传播能力的证明，继而向企业索取高额广告费。
- 提升自己的某些KPI数值，来迎合投资人的喜好。

➤刷量

- 有违基本的商业道德与伦理。
- 扰乱了正常的市场秩序。
- 与之相关的法律冲突案例，正在慢慢浮现。

案件背景



復旦大學


➤ 看榜公司：


- 一家作为中国移动互联网内容创业服务平台。
- 下属新榜网站 www.newrank.cn。

➤ 新榜指数：

- 基于微信（公众号、视频号）、抖音、小红书、B站、快手等主流内容平台，新榜提供包括新抖、新视、新红、新站、新快在内的数据工具，为用户带来实时热门素材、品牌声量、直播电商等全面的数据监测分析能力，同时提供基于跨平台用户画像的企业定制SAAS产品。
- 作为中国提供微信公众号、视频号内容数据价值评估的专业机构，新榜拥有稳定和海量的微信数据能力，据此发布微信公众号、视频号影响力排行榜（日、周、月、年），以及细分的类别行业榜和地域榜。新榜每月和每年发布的中国微信500强榜单是行业公认的权威标准。
- 建立在领先稳定的技术能力和保障的优先协议基础上，由复旦大学新闻学院提供全方位学术支持，新榜依据公开透明和不断优化的算法公式来生成新榜指数，作为各类榜单排名的基础依据。新榜指数算法公式可参见白皮书。依托分钟级监测和周期数据对比等技术，新榜对数据造假现象实施净化，确保公正权威。

➤ 注册地：上海市崇明区





鲸媒体讯（文/Aaron）：

2016年4月7日，新榜在其微信公众号第二条图文中发布了《关于7个微信公众号阅读数造假的查处说明/新榜公告》，文中指出“今年3月以来，综合近期所接到的举报线索，再次确认7个微信公众号阅读数有**严重造假嫌疑**，新榜已将这7个账号剔除出样本库，也就是说，除非申诉成功，这些涉嫌主动造假的微信公众号将不会再出现在新榜发布的任何榜单内。”其中这7个帐号之中就包括了VIPABC微信公众号。

背景：案件由来



復旦大學

鲸媒体讯（文/Aaron）：

事发的第二天，也就是2016年4月8日，VIPABC通过授权律师事务所向新榜发出律师函，要求“删除不实言论，刊登澄清声明”。鲸媒体也和VIPABC的相关负责人取得了联系，对方回应：“微信目前是正常运营的，这件事不排除竞争对手的恶意举报，目前法务部门在处理这件事。”

崇明县人民法院
传票

案号	(2016)沪0230民初302号
案由	名誉权
被传唤人	上海看信信息科技有限公司
工作单位或住址	
传唤事由	开庭审理
应到时间	2016年9月23日13时30分
应到处所	崇明县城桥镇育麟桥路351号第二法庭

注意事项：1、被传唤人必须准时到达应到处所；
2、本票由被传唤人携带来院报到；
3、被传唤人收到传票后，应在送达回证上签名；
4、个人到庭时，请携带居民身份证；
单位到庭时，请携带营业执照副本及法定代表人身份证明。

审判员 曹志华
书记员 王
电话 3961241
二〇一六年 月 日

原定于2016年9月13日下午14:00
的庭审因故取消。

本联送达被传唤人



復旦大學

分析思路

分析思路



復旦大學

如何从数据的角度来分析问题：

➤ Q1：我们要做什么事情？

➤ A1：通过数据验证VIPABC的数据是否“异常”

➤ Q2：做这件事情需要什么样的数据？如何获得？

➤ A2：见下文

➤ Q3：拿到这些数据后要如何分析？

➤ A3：见下文



復旦大學

数据介绍

数据：抽样方法



復旦大學

- 理想方案1：获取微信服务器的后台数据
- 可行性：腾讯数据不公开，不具可行性
- 理想方案2：获取淘宝网站交易记录
- 可行性：阿里数据不公开，不具可行性
- 实际方案：
 - 对于某个公众号实施监测
 - 如果该公众号发文，则定期（5分钟左右，会因为网络速度稍有变化）观测，直至发文后次日24时。
 - 记录观测时间，阅读数，点赞数。（最多10万）

数据：抽样方法



復旦大學

➤ 总原则：确保方法的严谨性，确保过程可重复性

➤ 公正性

➤ 数据的获取必须由独立第三方进行

➤ 新榜不得对其进行任何明示或暗示

➤ 可对比性

➤ 由于VIPABC是一家从事英语培训的企业，我们选择了名称中有“英语”字样的公众号（449个）。

➤ 考虑到成本等因素，从这些公众号中再等概率随机抽取66个。

➤ 采样（监测）的过程必须同时进行

数据：抽样方法



復旦大學

➤ 三次监测：

➤ 诉讼前：2016年3月

➤ 新榜对数据是否造假进行的自行监测，后依据此次数据发布公告

➤ 诉讼后：2016年6月

➤ 为了验证统计分析方法是否有效，新榜进行的监测

➤ 诉讼后：2016年7月

➤ 委托第三方进行监测，获取数据

数据：抽样结果



復旦大學

- 监测时间：2016年7月27日8时-2016年8月1日24时。
- 被监测公众号（含VIPABC在内）共计66个。
- 这些公众号在监测时间段内发的文章均作为观测。
- 共计监控261篇文章，数据记录93687条。
- 每隔约5-10分钟，记录下该文章的累计阅读数。（因为网络速度影响，无法精确定时监测）

数据：抽样结果



复旦大学

	标题名称	公众号名称	发布时间	位置	阅读数	点赞数	阅读增长数	点赞增长数	文章地址	更新时间
1	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	1955	0	0	0	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 20:33:35
2	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	2705	3	750	3	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 20:38:57
3	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	4543	40	1838	37	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 20:49:20
4	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	5559	118	1016	78	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 20:54:43
5	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	7845	271	2286	153	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 21:05:26
6	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	8258	271	413	0	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 21:11:01
7	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	8428	272	170	1	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 21:21:25
8	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	9001	273	573	1	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 21:26:46
9	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	9593	273	592	0	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 21:32:09
10	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	17485	273	7892	0	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 21:37:09
11	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	24855	274	7370	1	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 21:47:27
12	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	24919	275	64	1	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 21:53:08
13	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	25418	318	499	43	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 21:58:31
14	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	25665	320	247	2	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 22:10:10
15	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	25743	320	78	0	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 22:15:54
16	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	25905	320	162	0	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 22:26:31
17	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	25984	320	79	0	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 22:31:51
18	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	26064	321	80	1	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 22:37:15
19	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	26124	322	60	1	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 22:42:14
20	男人英语好到底有多重要：看看科技大佬们的“鄙视链”	VIPABC_July	2016-07-27 20:25:59	1	26257	323	133	1	http://mp.weixin.qq.com/s?__biz=MzA4MzQ4MzAxOQ==...	2016-07-27 22:52:38



復旦大學

对传播量化指标的数据分析

对传播量化指标的数据分析



復旦大學

➤ 图例约定：

- 红色表示VIPABC的3月份公众号文章阅读数据
- 蓝色表示VIPABC的6月份公众号文章阅读数据
- 橙色表示VIPABC的7月份公众号文章阅读数据
- 绿色表示非VIPABC的公众号文章阅读数据



復旦大學


静态分析 对阅读量分布的分析

静态分析：阅读量分布



復旦大學

文章总阅读数直方图




- 大量文献和实证分析显示，文章阅读量的一般规律是：大多数文章只有少部分人阅读，而只有少量文章阅读人数会非常多，分布呈现“右偏”的特征。这就是所谓的“长尾”现象。
- 左图为被监测公众号在7月份观测期间所有文章的阅读量的直方图（计量单位为频数）。可以看出，其分布服从上述“右偏”特征。

静态分析：阅读量分布



復旦大學

文章总阅读数对比箱线图



➤左图对比可知：非VIPABC的文章总阅读数分布呈现“右偏”特征，而VIPABC的文章总阅读数呈现出“左偏”特征。

復旦大學




复旦大学管理学院统计与数据科学系 黄达 版权所有，保留一切权利！
该课件受版权法保护，不得擅自复制、分发和传播。

静态分析：头条文章阅读量分布



復旦大學

各公众号头条总阅读量箱线图



VIPABC公众号的文章阅读量（橙色）绝对数量很多，但是四分位间距很小，即文章与文章之间阅读量变异很小。



復旦大學

动态分析1


对阅读量随时间变化的分析

动态分析：阅读量流量与存量的对比




復旦大學

头条阅读增长数趋势图



头条阅读数增长趋势图




左图为不同时间段内的阅读量（流量），右图为累计阅读量（存量）。显然右侧图更能够展现数据所含的信息。

动态分析：阅读量与时间的关系




復旦大學

头条阅读数增长趋势图



头条阅读数增长趋势图
(总阅读数5000-40000)



VIPABC公众号的文章阅读量（橙色）呈现急速跃升，然后迅速持平的现象。

复旦大学管理学院统计与数据科学系 黄达 版权所有，保留一切权利！



动态分析2


对阅读比率随时间变化的分析

动态分析2：阅读比例与时间的关系




復旦大學

头条阅读比例增长趋势图



头条阅读比例增长趋势图



VIPABC公众号的文章阅读比率（橙色）呈现急速跃升，然后迅速持平的现象。

复旦大学管理学院统计与数据科学系 黄达 版权所有，保留一切权利！
该课件受版权法保护，不得擅自复制、分发和传播。



復旦大學


综合三次监测数据的分析

静态分析：所有文章阅读量分布



復旦大學

各公众号头条总阅读数箱线图
(含X公司3月、6月数据)



VIPABC公众号的文章阅读量在这三个月内在持续攀升，但是四分位间距越来越小。


复旦大学管理学院统计与数据科学系 黄达 版权所有 保留一切权利！

动态分析1：阅读量与时间的关系




復旦大學

全部公众号头条阅读数增长趋势图
(含X公司3月、6月数据, 阅读量5000-40000)



X公司头条阅读数增长趋势图
(含X公司3月、6月数据, 阅读量5000-40000)



VIPABC公众号的文章阅读量在这三个月内持续增高, 而且上升的速度也越来越快。


复旦大学管理学院统计与数据科学系 黄达 版权所有, 保留一切权利! 该课件受版权法保护, 不得擅自复制、分发和传播。

动态分析2：阅读比例与时间的关系




復旦大學

全部公众号头条阅读比例增长趋势图
(含X公司3月、6月数据, 阅读量5000-40000)



X公司头条阅读比例增长趋势图
(含X公司3月、6月数据, 阅读量5000-40000)





復旦大學

案件的审理与后续

案件的审理



復旦大學



案件的审理



復旦大學



案件的审理



復旦大學



案件的后续



復旦大學

序号	公众号	帐号名	平均阅读数	平均阅读数变化	平均阅读数变化占比
1	被窝阅读	BeiWoYueDu	10572	-86146	-89%
2	鬼脚七	taobaoguijiaoqi	16741	-64010	-79%
3	一起神二逼	yqserbi	41819	-58182	-58%
4	她生活	Wchatherstyle	10691	-52490	-83%
5	水木文摘	mweishijie	39588	-49043	-55%
6	Camelia山茶花	hicamelia	13076	-40715	-76%
7	为你读诗	thepoemforyou	20963	-40575	-66%
8	爱奇艺	i-qilv	9024	-38076	-81%
9	Msrunning阿素	wwx_shoo	25705	-37100	-59%
10	大饼穿搭札记	modishvane	20381	-36321	-64%

- 2016年9月28日腾讯关闭了微信公众号的部分网络端口。
- 众多刷阅读量程序失效，大量刷量的公众号浮出水面。
- VIPABC当日的阅读量为前几天阅读量的5%。（已做公证保全证据）
- 在宣判前一天，VIPABC撤诉

案件的后续



復旦大學

➤ 在宣判前一天，VIPABC撤诉

资讯正文

app.finchina.com/finchinaAPP/newsDetail.html?type=litigate&id=41D2D8B10D5935E0FEA461F0E039E7DA&sharetype=1&code=a606528ba2475f0b725a1e40797420ab&channelCode=1

应用 Daily Check Misc Reference Statistics Video 微信公众平台 DMD2020网课考...

北京创意麦奇教育信息咨询有限公司与上海看榜信息科技有限公司名誉权纠纷一案民事裁定书

崇明县人民法院 2016-10-25

北京创意麦奇教育信息咨询有限公司与上海看榜信息科技有限公司名誉权纠纷一案民事裁定书

崇明县人民法院

民事裁定书

(2016)沪0230民初3092号

原告北京创意麦奇教育信息咨询有限公司，住所地北京市。法定代表人杨磊，总经理。委托代理人张杰。委托代理人熊定中，北京华沛德权律师事务所律师。被告上海看榜信息科技有限公司，住所地上海市崇明县。法定代表人徐俊，总经理。委托代理人熊磊之，上海大邦律师事务所律师。委托代理人王秀先，上海大邦律师事务所律师。原告北京创意麦奇教育信息咨询有限公司诉被告上海看榜信息科技有限公司名誉权纠纷一案中，因原告北京创意麦奇教育信息咨询有限公司于2016年10月25日以决定通过其他方式与被告解决纠纷为由，向本院提出撤诉申请。本院经审查认为，原告自愿申请撤诉，符合有关法律规定，应予准许。据此，依据《中华人民共和国民事诉讼法》第一百四十五条第一款之规定，裁定如下：准许原告北京创意麦奇教育信息咨询有限公司撤回起诉。案件受理费人民币26313元，减半收取计人民币13156.50元，由原告北京创意麦奇教育信息咨询有限公司负担。

审判员 茅玲玲

二〇一六年十月二十五日

书记员 陈凌

附：相关法律条文

<https://app.finchina.com/finchinaAPP/newsDetail.html?type=litigate&id=41D2D8B10D5935E0FEA461F0E039E7DA&sharetype=1&code=a606528ba2475f0b725a1e40797420ab&channelCode=1>



復旦大學

本课要点小结

学习要点小结



復旦大學

➤掌握描述统计的基本概念并能够熟练应用

- 均值

- 中位数、四分位数、四分位间距

- 分布

- 带有时间因素的数据表达

➤数据的可比性

- 统计口径的一致性

- 各种自然属性的一致/相似性

- 抽样方法

➤数据对比的角度

- 静态分析与动态分析

- 流量分析与存量分析

- 绝对量分析与相对量分析